Desafio Técnico — Cientista de Dados Pleno

Squad WhatsApp · Prefeitura do Rio

Proposta Teste A/B

Maria Luiza Wuillaume

28 de abril de 2026

1 Contexto e Motivação

O algoritmo `PhoneScorer` propõe um ranking interpretável baseado em três sinais (confiabilidade da fonte, atualidade e histórico de engajamento) em substituição às estratégias atualmente em uso (envio aleatório ou ordem alfabética).

Para avaliar seu impacto, definimos um experimento A/B no qual:

- o **grupo controle** utiliza a estratégia atual de seleção de telefones (aleatório ou ordem alfabética);
- o **grupo tratamento** utiliza o ranking gerado pelo `PhoneScorer`.

O objetivo é verificar se a nova abordagem produz ganhos reais no motor de disparos de WhatsApp, com base em métricas de engajamento bem definidas ao longo de um período controlado.

2 Métricas

2.1 Métrica Primária

Proporção de CPFs com alta taxa de leitura:

A taxa de leitura por CPF é definida como:

$$\text{ReadRate}_{\text{CPF}} = \frac{\text{Total de mensagens lidas}}{\text{Total de mensagens enviadas}}$$

Definimos a variável indicadora:

$$\text{HighRead}_{\text{CPF}} = \begin{cases} 1, & \text{se ReadRate}_{\text{CPF}} \geq 0.75 \\ 0, & \text{caso contrário} \end{cases}$$

A métrica primária é:

$$p_{\text{read}} = \frac{\sum \text{HighRead}_{\text{CPF}}}{n}$$

onde n é o número total de CPFs considerados no experimento.

2.2 Métrica Secundária

Proporção de CPFs com alta taxa de entrega:

A taxa de entrega por CPF é definida como:

$$\text{DeliveryRate}_{\text{CPF}} = \frac{\text{Mensagens com status delivered ou read}}{\text{Total de mensagens enviadas}}$$

Definimos a variável indicadora:

$$\text{HighDelivery}_{\text{CPF}} = \begin{cases} 1, & \text{se DeliveryRate}_{\text{CPF}} \geq 0.9 \\ 0, & \text{caso contrário} \end{cases}$$

A métrica secundária é:

$$p_{\text{delivery}} = \frac{\sum \text{HighDelivery}_{\text{CPF}}}{n}$$

3 Hipóteses

3.1 Hipótese Nula (H_0)

$$H_0 : p_{\text{read, tratamento}} \leq p_{\text{read, controle}}$$

A hipótese nula afirma que o grupo tratamento (`PhoneScorer`) não aumenta a proporção de CPFs com alta taxa de leitura em relação ao grupo controle.

3.2 Hipótese Alternativa (H_1)

$$H_1 : p_{\text{read, tratamento}} > p_{\text{read, controle}}$$

A hipótese alternativa afirma que o grupo tratamento (`PhoneScorer`) aumenta a proporção de CPFs com alta taxa de leitura em relação ao grupo controle.

4 Teste Estatístico

A comparação entre os grupos é realizada por meio de um **teste de duas proporções (z-test)**, adequado para avaliar diferenças entre proporções em amostras independentes.

O teste é conduzido de forma unilateral à direita, com nível de significância $\alpha = 0.05$, avaliando se:

$$p_{\text{read, tratamento}} > p_{\text{read, controle}}$$

Rejeita-se H_0 se o p-value < 0.05.

A decisão final considera evidência de melhoria na métrica primária sem degradação relevante na métrica secundária.

5 Cálculo de Tamanho de Amostra

O tamanho de amostra necessário para o experimento foi estimado com base na métrica primária (proporção de CPFs com alta taxa de leitura).

Para o cálculo, foi utilizada a calculadora de Evan Miller:
https://www.evanmiller.org/ab-testing/sample-size.html

Os parâmetros foram definidos a partir da análise exploratória realizada no notebook `07_proporcao_cpfs_taxas.ipynb`.

- **Baseline (taxa atual)**: 70%, correspondente à proporção observada de CPFs com taxa de leitura $\geq 75\%$ (69.94% em 268,436 CPFs analisados).
- **Minimum Detectable Effect (MDE)**: 5 pontos percentuais, representando um aumento de 70% para 75%.
- **Nível de significância**: $\alpha = 0.05$
- **Poder estatístico**: $1 - \beta = 0.80$

Com esses parâmetros, o tamanho de amostra estimado foi de aproximadamente:

$$n \approx 1335 \text{ CPFs por grupo}$$

6 Duração do Experimento

A duração do experimento foi definida considerando o tamanho de amostra necessário e a variação temporal no comportamento dos usuários. Recomenda-se uma duração mínima de **7 dias consecutivos**, suficiente para capturar um ciclo semanal completo (dias úteis e finais de semana).

Com base no tamanho de amostra estimado de aproximadamente 2670 CPFs no total, é necessário observar em média cerca de:

$$\approx 382 \text{ CPFs por dia}$$

para atingir o volume necessário ao longo de 7 dias.

Adicionalmente, para cada mensagem enviada, considera-se uma janela de **24 horas** para observação de leitura. Dessa forma, as métricas de leitura e entrega são sempre calculadas considerando esse mesmo horizonte temporal, assegurando consistência entre os grupos.

7 Design do Experimento

Aspecto	**Grupo Controle**	**Grupo Tratamento**
Estratégia de Seleção	Aleatória ou alfabética (atual)	PhoneScorer
Critério de Alocação	Aleatório por CPF (50/50)	
Tamanho	1.335 CPFs por grupo	
Período	7 dias consecutivos	

Tabela 1: Estrutura do Teste A/B: alocação aleatória de CPFs a controle e tratamento.

Definições do Experimento

- **Unidade de Randomização:** CPF (não telefone). Cada CPF é alocado uma única vez a um dos grupos no início do experimento.
- **Persistência da Alocação:** A alocação é fixa ao longo de todo o experimento (*sticky assignment*), garantindo que um mesmo CPF não transite entre controle e tratamento.
- **Unidade de Análise:** As métricas são agregadas no nível de CPF.
- **Regra de Exposição:** Para cada CPF, o grupo tratamento (PhoneScorer) seleciona o **telefone com maior score** (top-1) para envio da mensagem. O grupo controle segue a estratégia atual (aleatória ou alfabética).

- **Janela de Observação:** Para cada mensagem enviada, o status de entrega e leitura é avaliado após uma janela fixa de 24 horas.
- **Critérios de Inclusão:** A análise considera apenas mensagens com janela de observação completa de 24 horas. CPFs sem envios no período não são incluídos no cálculo das métricas.
- **Balanceamento:** A alocação é realizada de forma balanceada entre os grupos (50/50), resultando em aproximadamente 1.335 CPFs por grupo.
- **Independência:** Cada CPF é tratado como uma observação independente no experimento.