Desafio Técnico — Cientista de Dados Pleno

Squad WhatsApp · Prefeitura do Rio

Relatório Consolidado de Análise

Maria Luiza Wuillaume

27 de abril de 2026

Sumário

Convenção de classificação **2**

1 Qualidade das Fontes de Dados **3**
1.1 Pergunta de negócio . . . 3
1.2 Roteiro da análise . . . 3
1.3 Taxa de entrega bruta por sistema . . . 3
1.4 Taxa média de entrega por telefone . . . 4
1.5 Probabilidade de *Telefone HighDelivery* . . . 5
1.6 Conclusão . . . 6

2 Janela de Atualidade dos Telefones **6**
2.1 Pergunta de negócio . . . 6
2.2 Roteiro da análise . . . 6
2.3 Proporção por ano de atualização . . . 7
2.4 Curva de decaimento contínuo . . . 8
2.5 Árvores de decisão por sistema . . . 9
2.6 Conclusão . . . 10

3 Ranking de Sistemas **10**
3.1 Pergunta de negócio . . . 10
3.2 Decisões metodológicas . . . 10
3.3 Relação entre qualidade e falha . . . 11
3.4 Ranking de Confiabilidade . . . 12
3.5 Ranking Operacional . . . 12
3.6 Conclusão . . . 13

4 Análise por DDD **13**
4.1 Pergunta de negócio . . . 13
4.2 Distribuição de volume e incerteza . . . 13
4.3 DDDs com estimativas confiáveis . . . 14
4.4 Conclusão . . . 14

5 Algoritmo de Ranqueamento de Telefones (`PhoneScorer`) 15
5.1 Objetivo . . . 15
5.2 Como o algoritmo funciona . . . 15
5.3 Comparação dentro de cada CPF . . . 15
5.4 Tratamento de dados incompletos . . . 15
5.5 Saída . . . 16

6 Proposta de Teste A/B 16
6.1 Contexto e Motivação . . . 16
6.2 Métricas . . . 16
6.2.1 Métrica Primária . . . 16
6.2.2 Métrica Secundária . . . 17
6.3 Hipóteses . . . 17
6.3.1 Hipótese Nula (H_0) . . . 17
6.3.2 Hipótese Alternativa (H_1) . . . 17
6.4 Teste Estatístico . . . 17
6.5 Cálculo de Tamanho de Amostra . . . 18
6.6 Duração do Experimento . . . 18
6.7 Design do Experimento . . . 18

Definições

Ao longo de todo o projeto adotamos duas categorias binárias de qualidade, aplicáveis tanto a um **telefone** quanto a um **CPF**:

Categoria	Definição	Limiar
HighDelivery	Taxa de entrega = (delivered + read)/total_disparos	$\geq 90\%$
HighRead	Taxa de leitura = read/total_disparos	$\geq 75\%$

A partir dessas definições, utilizamos a notação probabilística $P(\cdot)$ para representar proporções na base. Por exemplo, $P(\text{Telefone HighDelivery})$ corresponde à fração de telefones classificados como HighDelivery (alta taxa de entrega). Da mesma forma, podem ser definidas probabilidades condicionais em diferentes níveis de agregação (por sistema, DDD ou CPF), conforme o contexto da análise.

1 Qualidade das Fontes de Dados

Notebook de referência: `notebooks/02_qualidade_fontes.ipynb`.

1.1 Pergunta de negócio

A base do RMI agrega telefones vindos de múltiplos sistemas de origem. Antes de decidir *qual telefone disparar*, precisamos saber *quais fontes são mais confiáveis*: um sistema que historicamente entrega bem deve pesar mais do que um sistema com alta taxa de falha.

1.2 Roteiro da análise

A análise foi conduzida em três passos, cada um endereçando uma limitação do anterior:

1. **Taxa de entrega bruta por sistema**, com intervalo de confiança (IC) de Wilson.
2. **Taxa média por telefone** dentro de cada sistema, para mitigar o viés de telefones com alto volume de disparos.
3. **Probabilidade de *Telefone HighDelivery*** por sistema — abordagem final adotada.

1.3 Taxa de entrega bruta por sistema

Para cada sistema, estimamos a taxa de entrega como a proporção de disparos com status $\in \{\texttt{delivered}, \texttt{read}\}$ em relação ao total de envios, juntamente com o respectivo intervalo de confiança de 95% (Wilson).

A Tabela 1 apresenta os valores estimados, enquanto a Figura 1 ilustra visualmente as diferenças entre os sistemas.

Sistema	**Total envios**	**Taxa de entrega**	**IC 95%**
Sistema E	197.221	98,92%	[98,87%; 98,96%]
Sistema D	6.829	96,06%	[95,57%; 96,50%]
Sistema B	243.851	94,94%	[94,85%; 95,02%]
Sistema C	19.781	94,84%	[94,52%; 95,14%]
Sistema A	170.391	94,11%	[94,00%; 94,22%]
Sistema F	110.602	92,29%	[92,13%; 92,45%]

Tabela 1: Taxa de entrega bruta por sistema com IC de Wilson.

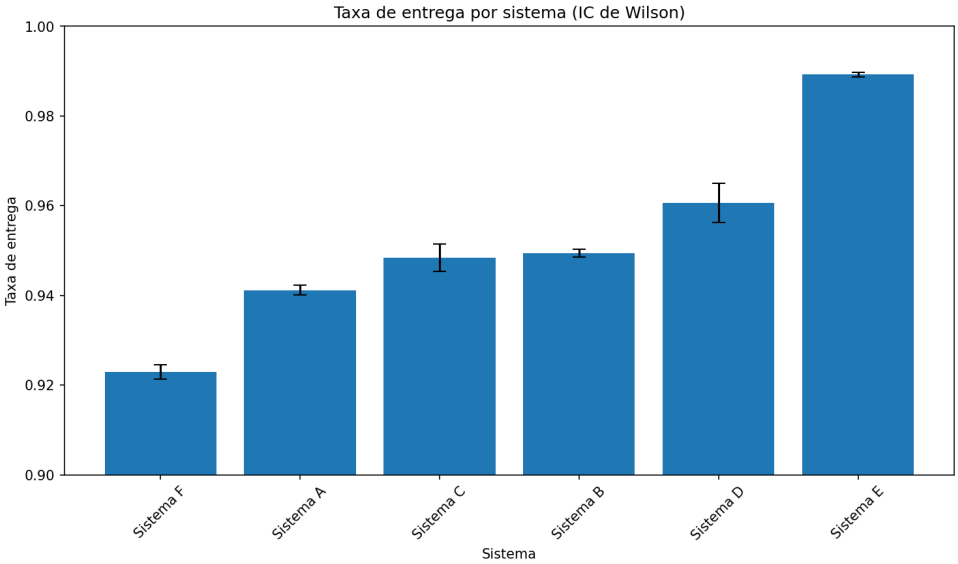

Figura 1: Taxa de entrega por sistema (IC de Wilson).

A Figura 1 sugere que o Sistema E apresenta o melhor desempenho em termos de taxa de entrega, seguido por sistemas com resultados relativamente próximos. No entanto, como evidenciado pela Tabela 1, essa métrica é agregada por volume total de envios e pode estar sujeita a viés: poucos telefones com alto volume de disparos podem influenciar desproporcionalmente o resultado.

1.4 Taxa média de entrega por telefone

Para reduzir esse viés, cada *telefone* passa a ser a unidade de análise: calculamos a taxa de entrega individual e, em seguida, agregamos por sistema (média, desvio padrão e percentis).

A Tabela 2 resume essas estatísticas, enquanto a Figura 2 apresenta a média e a dispersão por sistema.

Sistema	**Média**	**Desvio**	**P10**	**P50**
Sistema E	99,22%	0,073	1,00	1,00
Sistema D	96,79%	0,171	1,00	1,00
Sistema B	95,66%	0,198	1,00	1,00
Sistema C	95,36%	0,202	1,00	1,00
Sistema A	94,66%	0,220	1,00	1,00
Sistema F	93,04%	0,251	1,00	1,00

Tabela 2: Distribuição da taxa de entrega *por telefone* dentro de cada sistema.

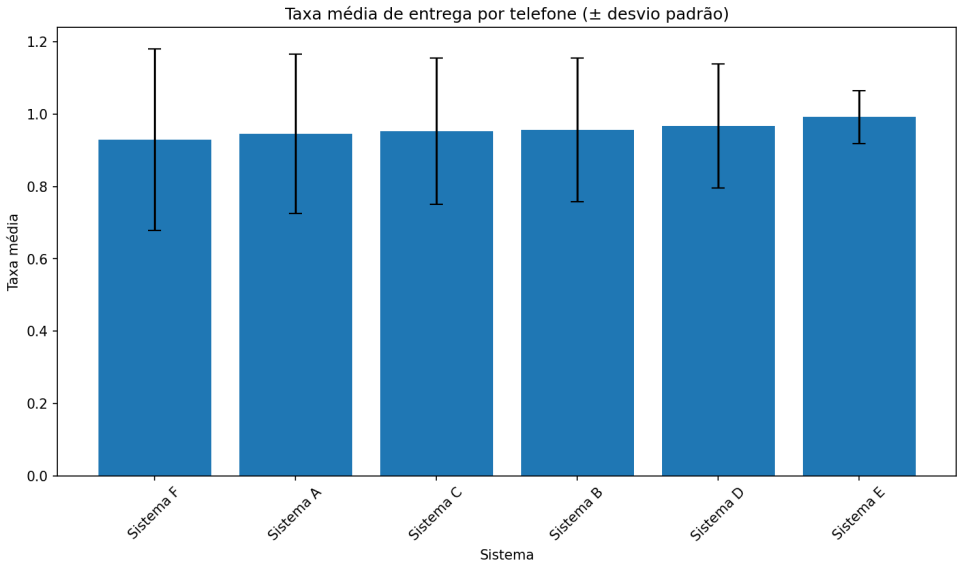

Figura 2: Taxa média de entrega por telefone (± desvio padrão).

A Figura 2 e a Tabela 2 mostram que as médias são elevadas e muito próximas entre si, enquanto os desvios padrão permanecem relativamente altos. Além disso, os percentis indicam forte concentração de telefones com taxa igual a 1, o que torna as distribuições bastante semelhantes entre os sistemas. Em conjunto, esses fatores reduzem o poder discriminatório dessa abordagem.

1.5 Probabilidade de *Telefone HighDelivery*

Diante dessas limitações, adotamos uma métrica binária ao nível de telefone: classificamos cada telefone como **Telefone HighDelivery** se sua taxa de entrega é $\geq 90\%$.

A Tabela 3 apresenta a proporção de telefones classificados como HighDelivery em cada sistema, enquanto a Figura 3 permite comparar visualmente essas probabilidades com seus respectivos intervalos de confiança.

Sistema	**Telefones**	P(HighDelivery)	**IC 95%**
Sistema E	135.266	98,66%	[98,60%; 98,72%]
Sistema D	4.680	96,43%	[95,86%; 96,93%]
Sistema B	175.516	95,15%	[95,05%; 95,25%]
Sistema C	11.770	94,51%	[94,09%; 94,91%]
Sistema A	122.918	94,19%	[94,06%; 94,32%]
Sistema F	81.348	92,65%	[92,47%; 92,83%]

Tabela 3: P(Telefone HighDelivery | sistema) com IC de Wilson.

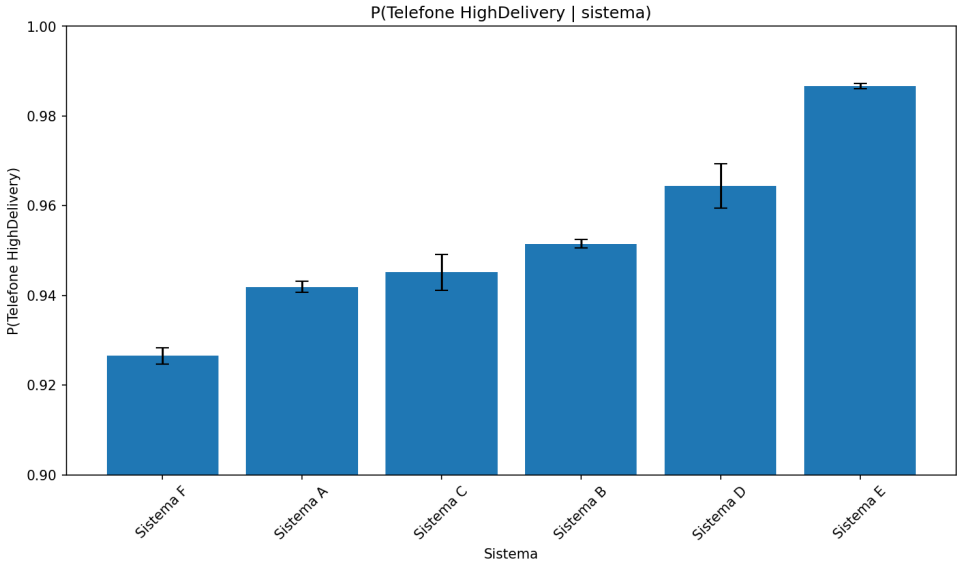

Figura 3: Probabilidade de Telefone HighDelivery por sistema.

1.6 Conclusão

A Figura 1 indica inicialmente o Sistema E como o mais performático, e esse resultado se mantém na Figura 3, baseada em uma métrica mais robusta ao nível de telefone. A proximidade entre os resultados sugere que o viés de volume não alterou significativamente o ordenamento dos sistemas, embora tenha motivado a adoção de uma abordagem metodologicamente mais adequada.

Assim, a probabilidade $P(\text{Telefone HighDelivery} \mid \text{sistema})$ é adotada como medida de confiabilidade dos sistemas, por equilibrar interpretabilidade, robustez a viés e capacidade de discriminação.

2 Janela de Atualidade dos Telefones

Notebook de referência: `notebooks/03_janela_atualidade.ipynb`.

2.1 Pergunta de negócio

Deseja-se investigar se o tempo decorrido desde a última atualização do telefone no sistema de origem (`registro_data_atualizacao`) impacta a probabilidade de sucesso do disparo, isto é, se telefones mais antigos apresentam pior desempenho do que telefones mais recentemente atualizados e, consequentemente, se existe um **prazo de validade** para a utilidade desses registros.

2.2 Roteiro da análise

A análise foi conduzida em três etapas progressivamente mais refinadas:

1. Comparar a proporção de *Telefone HighRead* por ano de atualização.
2. Avaliar o decaimento contínuo em função dos dias desde a última atualização.

3. Ajustar modelos simples por sistema para identificar pontos de corte específicos.

2.3 Proporção por ano de atualização

A primeira abordagem consistiu em comparar a proporção de *Telefone HighRead* (telefones com alta taxa de leitura) agrupando os registros pelo ano da última atualização.

A Figura 4 apresenta a visão agregada, enquanto a Figura 5 detalha o comportamento por sistema.

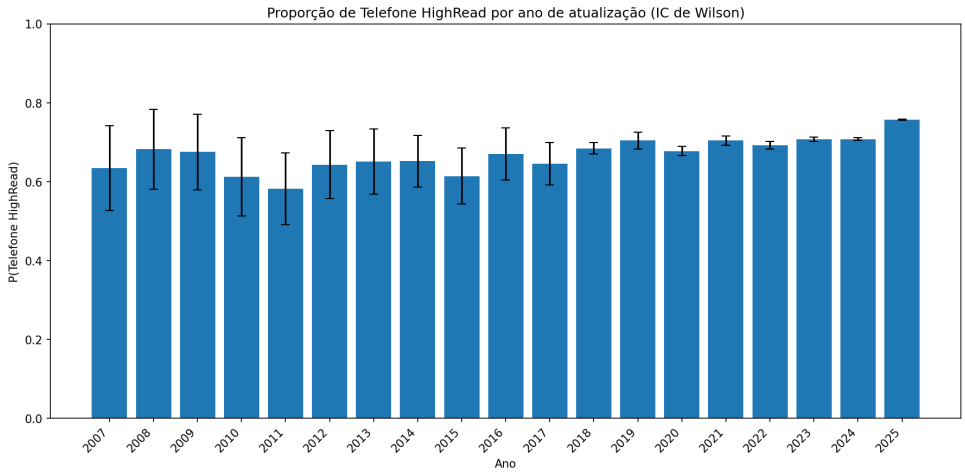

Figura 4: Proporção de Telefone HighRead por ano de atualização.

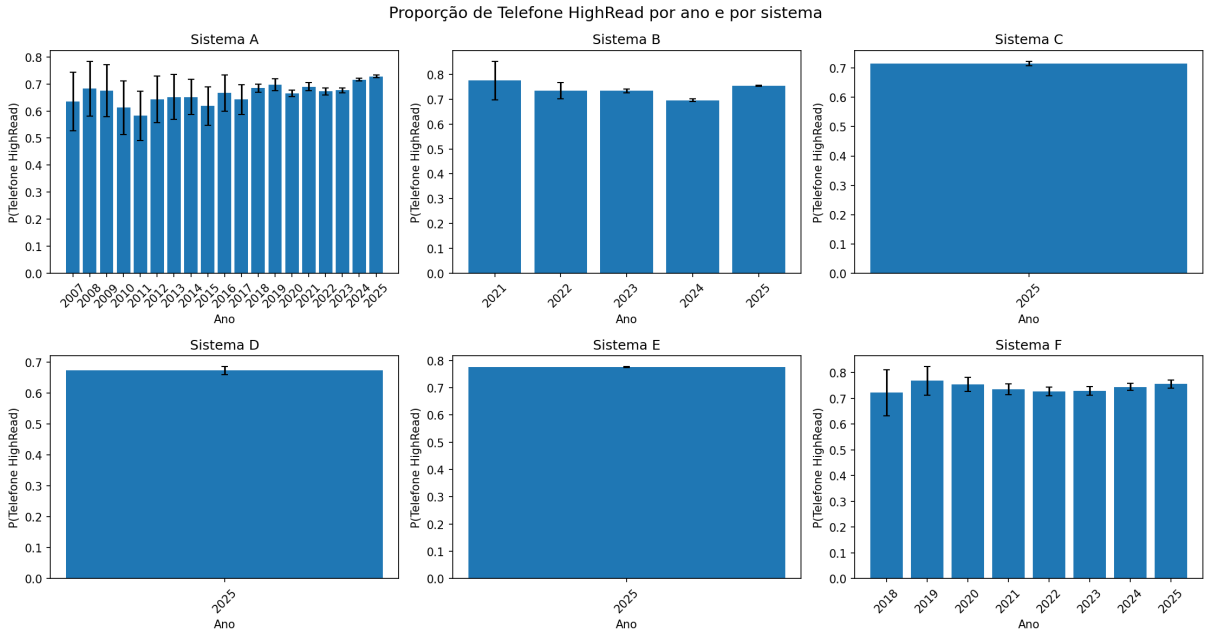

Figura 5: Proporção de Telefone HighRead por ano e por sistema.

As Figuras 4 e 5 mostram um resultado contra-intuitivo: não há um padrão claro de decaimento na proporção de *Telefone HighRead* à medida que consideramos anos mais antigos. Esse comportamento pode indicar que a granularidade anual não é suficientemente sensível para capturar a dinâmica de degradação da qualidade dos telefones.

2.4 Curva de decaimento contínuo

Para refinar a análise, passamos a considerar o número de dias desde a última atualização. Para cada limiar x, mantemos apenas os telefones com tempo desde a última atualização maior ou igual a x e estimamos a fração de *Telefone HighRead*.

A Figura 6 apresenta a curva agregada, enquanto a Figura 7 mostra o comportamento segmentado por sistema.

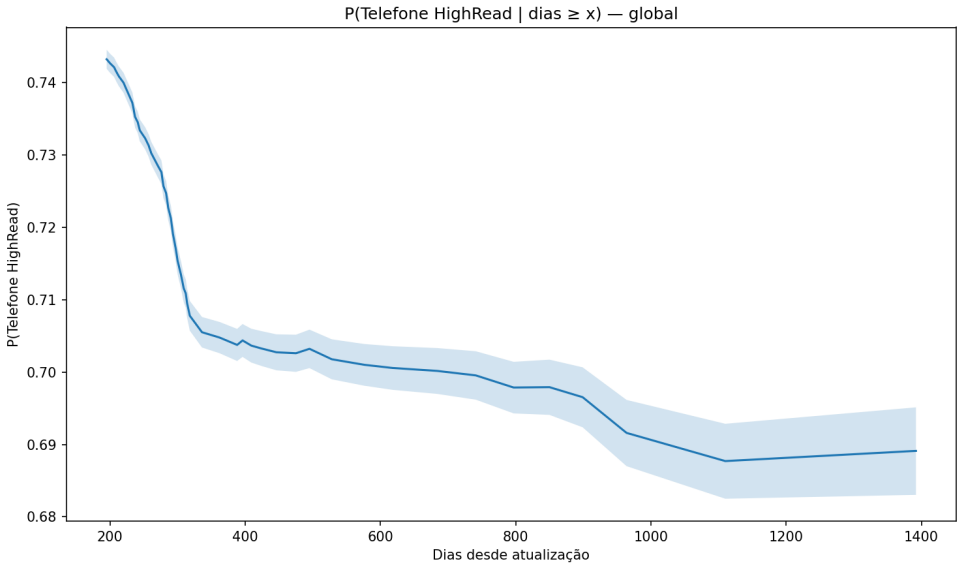

Figura 6: Curva de decaimento global.

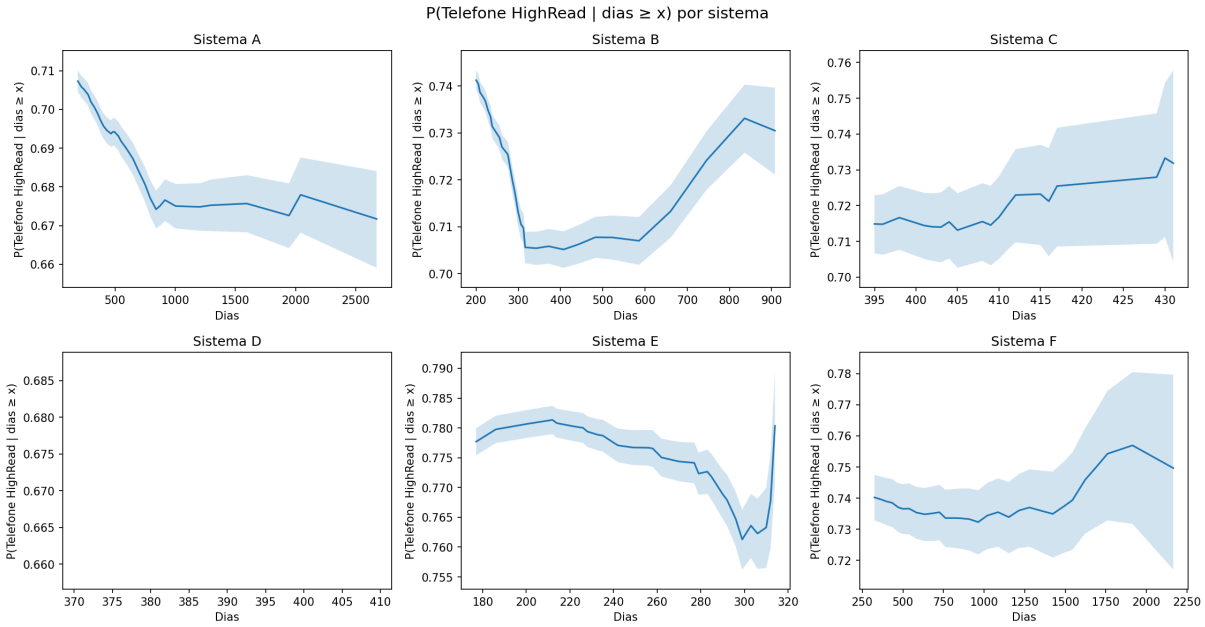

Figura 7: Curva de decaimento por sistema.

A Figura 6 sugere um decaimento da qualidade com o tempo. No entanto, a Figura 7 revela forte heterogeneidade entre os sistemas: enquanto alguns (como A e, em menor grau, E) apresentam a queda esperada, outros exibem comportamento praticamente estável ou até crescente. Essa divergência indica que o padrão agregado pode estar sendo influenciado por sistemas com maior volume de telefones, que dominam a proporção global. Por isso, uma regra única de validade temporal não é adequada.

2.5 Árvores de decisão por sistema

Diante dessa heterogeneidade, ajustamos uma árvore de decisão simples (com apenas um ponto de corte) para cada sistema. Esse modelo identifica, de forma automática, o número de dias desde a última atualização que melhor separa os *Telefones HighRead* dos demais.

O Sistema D foi excluído dessa etapa devido à baixa disponibilidade de informação sobre data de atualização: cerca de 91% dos registros não possuem esse dado preenchido.

A Tabela 4 resume as regras extraídas dessas árvores, juntamente com as probabilidades estimadas de *Telefone HighRead* em cada região.

Sistema	**Regra**	P(Telefone HighRead)
Sistema A	dias ≤ 816	72,54%
Sistema A	dias > 816	67,43%
Sistema B	dias ≤ 314	76,85%
Sistema B	dias > 314	70,56%
Sistema C	dias > 428	73,33%
Sistema C	dias ≤ 428	71,19%
Sistema E	dias > 186	78,02%
Sistema E	dias ≤ 186	72,91%
Sistema F	dias ≤ 604	75,60%
Sistema F	dias > 604	73,45%

Tabela 4: Regras de atualidade extraídas das árvores de decisão.

2.6 Conclusão

Diante da heterogeneidade observada na Figura 7, a construção de um único prazo de validade não se mostra adequada. Em vez disso, foram ajustadas árvores de decisão simples por sistema para identificar pontos de corte que isolam regiões com maior e menor proporção de *Telefone HighRead*. Os resultados, apresentados na Tabela 4, evidenciam essas diferenças entre as fontes.

Embora as variações observadas sejam relativamente pequenas (em torno de 2 a 5 pontos percentuais na probabilidade de *Telefone HighRead*), elas ainda podem ser relevantes como um parâmetro auxiliar de priorização, especialmente quando combinadas com outros sinais no processo de decisão.

3 Ranking de Sistemas

Notebook de referência: `notebooks/04_ranking_sistemas.ipynb`.

3.1 Pergunta de negócio

Com base nas análises anteriores (Seções 1 e 2), deseja-se construir um **ranking de confiabilidade dos sistemas**, de modo a comparar objetivamente a qualidade das fontes e justificar, do ponto de vista quantitativo, por que um sistema apresenta melhor desempenho do que outro.

3.2 Decisões metodológicas

A construção do ranking seguiu três decisões principais:

- A métrica de qualidade adotada foi P(Telefone HighDelivery | sistema). Optou-se por utilizar *HighDelivery* (taxa de entrega $\geq 90\%$) em vez de *HighRead*, pois a taxa de entrega reflete diretamente a capacidade do sistema de fornecer contatos válidos e alcançáveis, enquanto a taxa de leitura depende de fatores externos, como perfil do usuário, conteúdo da mensagem e momento do disparo.

- A variável de atualidade não foi incorporada ao ranking. Conforme mostrado na Seção 2, a relação entre tempo desde a última atualização e qualidade dos telefones varia entre os

sistemas, com padrões distintos que dificultam uma comparação consistente sob uma única régua.

- Além do ranking de confiabilidade, foi construído um ranking operacional para incorporar a dimensão de escala. Um sistema pode apresentar alta confiabilidade, mas, se contribuir com poucos telefones, seu impacto no alcance total da campanha é limitado.

3.3 Relação entre qualidade e falha

Uma ideia inicial era incorporar ao ranqueamento uma dimensão de falhas. Para isso, avaliou-se a relação entre a probabilidade de *Telefone HighDelivery* e a probabilidade de falha, com o objetivo de verificar se essa métrica adicionaria informação complementar à análise de qualidade.

Ambas as probabilidades são calculadas ao nível de telefone. Em particular, a probabilidade de falha corresponde à fração de telefones de um sistema que apresentaram pelo menos uma falha em seus disparos.

A Figura 8 apresenta essa relação ao nível dos sistemas.

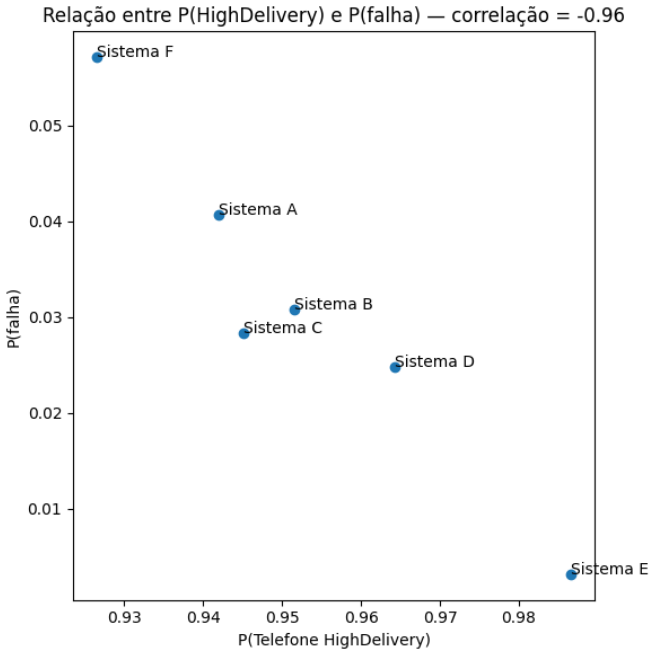

Figura 8: Relação entre probabilidade de HighDelivery e probabilidade de falha por sistema.

Observa-se uma forte correlação negativa entre as métricas (aproximadamente $-0{,}96$), com comportamento quase linear entre os sistemas: quanto maior a probabilidade de *HighDelivery*, menor a probabilidade de falha. O Sistema C apresenta um leve desvio desse padrão, mas sem impacto relevante na análise.

Diante desse resultado, conclui-se que a probabilidade de falha é redundante e, portanto, não foi incorporada ao ranqueamento.

3.4 Ranking de Confiabilidade

O ranking de confiabilidade é definido diretamente pela probabilidade de um telefone ser classificado como HighDelivery dado o sistema de origem:

$$\text{score} = P(\text{Telefone HighDelivery} \mid \text{sistema})$$

A Tabela 5 apresenta os valores estimados e o ordenamento dos sistemas.

Ranking	Sistema	Score
1	Sistema E	0,987
2	Sistema D	0,964
3	Sistema B	0,951
4	Sistema C	0,945
5	Sistema A	0,942
6	Sistema F	0,927

Tabela 5: Ranking de Confiabilidade (`deliverables/ranking_confiabilidade.csv`).

A diferença entre sistemas pode ser interpretada diretamente em termos probabilísticos. Por exemplo, a Tabela 5 mostra que um telefone proveniente do Sistema E tem probabilidade de HighDelivery de 98,7%, enquanto no Sistema F essa probabilidade é de 92,7%. Isso implica uma diferença de aproximadamente 6 pontos percentuais que, embora ppareça pequena, pode ser um sinal relevante para a priorização dos contatos.

3.5 Ranking Operacional

Embora o ranking de confiabilidade capture a qualidade das fontes, ele não considera o impacto de cada sistema na base. Para isso, define-se um segundo critério que combina qualidade e volume relativo de telefones:

$$\text{score}_{\text{op}} = 0{,}8 \cdot P(\text{HighDelivery} \mid \text{sistema}) + 0{,}2 \cdot \text{participação na base}$$

onde a *participação na base* corresponde à fração de telefones fornecidos pelo sistema em relação ao total de telefones disponíveis.

A Tabela 6 apresenta o ranking resultante, enquanto a Figura 9 permite comparar visualmente esses dois rankings.

Ranking	Sistema	Score
1	Sistema E	0,840
2	Sistema B	0,827
3	Sistema A	0,800
4	Sistema D	0,773
5	Sistema F	0,772
6	Sistema C	0,761

Tabela 6: Ranking Operacional (`deliverables/ranking_operacional.csv`).

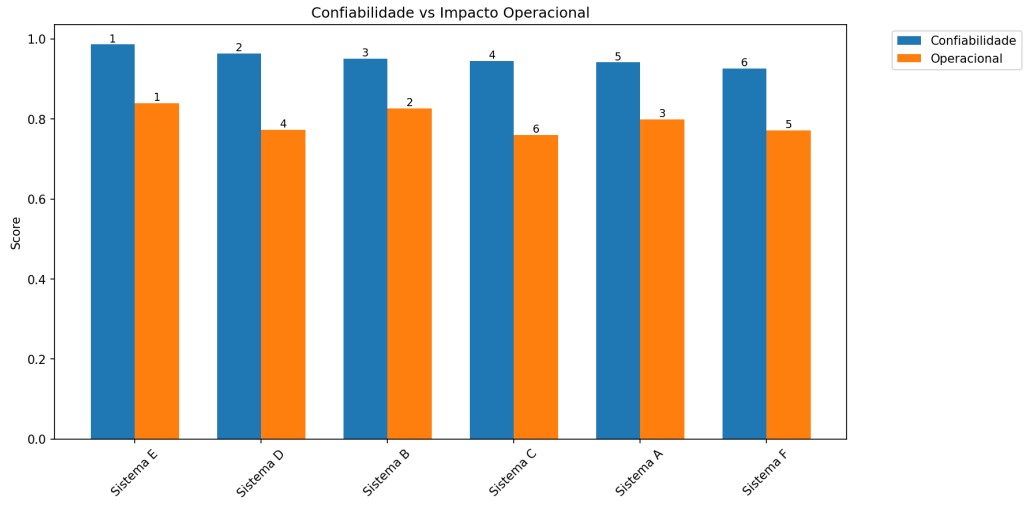

Figura 9: Confiabilidade vs Impacto Operacional.

3.6 Conclusão

A confiabilidade foi medida por $P(\text{Telefone HighDelivery} \mid \text{sistema})$. Como mostrado na Tabela 5, o Sistema E lidera o ranking de confiabilidade, seguido pelos Sistemas D e B.

Ao incorporar a participação relativa de cada sistema na base total de telefones, o ranking operacional (Tabela 6 e Figura 9) altera essa ordenação: o Sistema B sobe para a segunda posição, enquanto o Sistema D perde relevância. Embora seja altamente confiável, esse sistema fornece menos telefones.

Esse resultado mostra que qualidade e impacto operacional capturam dimensões distintas da contribuição de cada sistema. Por isso, foram construídos dois rankings complementares, que podem ser utilizados de acordo com o contexto: o ranking de confiabilidade, focado na qualidade dos telefones, e o ranking operacional, que incorpora o impacto de cada sistema na base de telefones.

4 Análise por DDD

Notebook de referência: `notebooks/05_analise_por_ddd.ipynb`.

4.1 Pergunta de negócio

Deseja-se avaliar se o DDD do telefone possui poder discriminatório para identificar telefones com alta chance de leitura.

4.2 Distribuição de volume e incerteza

A base contém **67 DDDs distintos**, com forte concentração de volume em poucos casos: o maior possui cerca de 249 mil telefones, enquanto alguns possuem apenas 2. Essa heterogeneidade impacta diretamente a precisão das estimativas.

A Tabela 7 apresenta a distribuição do erro das estimativas de $P(\text{Telefone HighRead} \mid \text{DDD})$. Observa-se que a mediana do erro é de aproximadamente 16%, indicando alta incerteza para a maioria dos DDDs e dificultando comparações diretas.

Estatística	**Erro do IC (semi-amplitude)**
Mínimo	0,18%
P25	11,54%
Mediana	16,13%
P75	24,66%
Máximo	45,90%

Tabela 7: Distribuição do erro das estimativas $P(\text{Telefone HighRead} \mid \text{DDD})$.

Diante disso, a análise foi restringida aos DDDs com erro $\leq 10\%$, de modo a considerar apenas estimativas mais estáveis.

4.3 DDDs com estimativas confiáveis

Após o filtro, restam apenas **12 DDDs**. A Figura 10 apresenta as estimativas de $P(\text{Telefone HighRead} \mid \text{DDD})$ para esses casos.

Observa-se que as probabilidades se concentram em uma faixa relativamente estreita (aproximadamente 60% a 75%), com intervalos de confiança frequentemente sobrepostos. Isso indica baixa separação entre os DDDs, mesmo quando considerados apenas os casos com maior volume.

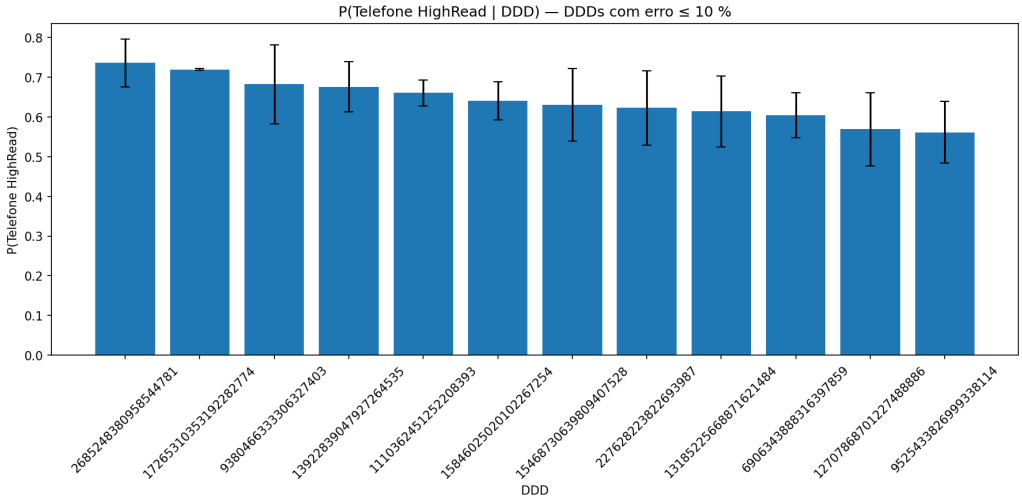

Figura 10: Probabilidade de *Telefone HighRead* por DDD.

4.4 Conclusão

A análise mostra que o DDD possui baixo poder discriminatório para identificar *Telefone HighRead*. A Tabela 7 evidencia que a maioria dos DDDs apresenta alta incerteza nas estimativas, enquanto a Figura 10 mostra que, mesmo entre os DDDs com estimativas mais confiáveis, as diferenças são pequenas e com sobreposição relevante dos intervalos de confiança.

Diante dessas limitações, o DDD não foi utilizado no algoritmo de ranqueamento de telefones `PhoneScorer`, apresentado na próxima seção.

5 Algoritmo de Ranqueamento de Telefones (`PhoneScorer`)

Especificação de referência: `src/phone_scorer.md`.
Implementação: `src/phone_scorer.py`.
Notebook de apoio: `notebooks/06_teste_phone_scorer.ipynb`.

5.1 Objetivo

Dado um CPF com múltiplos telefones associados, o objetivo é ordenar esses telefones de acordo com sua probabilidade de sucesso em um disparo, retornando os melhores candidatos para contato.

5.2 Como o algoritmo funciona

Para cada telefone, o algoritmo calcula um score entre 0 e 1, que combina três dimensões principais:

- **Qualidade da fonte:** telefones provenientes de sistemas mais confiáveis recebem pontuação maior, com base no ranking de confiabilidade construído anteriormente (Seção 3).
- **Atualidade do registro:** considera há quanto tempo o telefone foi atualizado. Esse efeito depende do sistema de origem, utilizando as regras específicas identificadas na análise de atualidade (Seção 2).
- **Engajamento histórico (quando disponível):** telefones que já apresentaram maior taxa de leitura no passado recebem pontuação mais alta.

Essas três dimensões são combinadas em uma única pontuação final por meio de uma média ponderada, com pesos parametrizáveis. Por padrão, atribui-se maior peso ao engajamento histórico (0,5), seguido pela qualidade da fonte (0,3) e pela atualidade do registro (0,2).

5.3 Comparação dentro de cada CPF

O algoritmo compara os telefones **apenas dentro do mesmo CPF**. Para isso, as pontuações são ajustadas de forma relativa dentro de cada conjunto de telefones, utilizando normalização min-max.

5.4 Tratamento de dados incompletos

Quando alguma informação não está disponível ou não permite diferenciação, o algoritmo atribui um valor neutro de 0,5, evitando favorecer ou prejudicar o telefone por falta de sinal. Isso ocorre, por exemplo, quando não há regra de atualidade aplicável para o sistema ou quando o CPF possui apenas um telefone.

5.5 Saída

Como resultado, o algoritmo retorna os telefones ordenados por score dentro de cada CPF, permitindo selecionar os melhores candidatos para contato (por exemplo, os dois melhores números).

Além da pontuação final, o resultado também inclui os componentes que contribuíram para o score, garantindo transparência e permitindo auditoria das decisões.

6 Proposta de Teste A/B

Documento autônomo: `deliverables/proposta_teste_ab/proposta_teste_ab.pdf`.
Insumo estatístico: `notebooks/07_proporcao_cpfs_taxas.ipynb`.

6.1 Contexto e Motivação

O algoritmo `PhoneScorer` propõe um ranking interpretável baseado em três sinais (confiabilidade da fonte, atualidade e histórico de engajamento) em substituição às estratégias atualmente em uso (envio aleatório ou ordem alfabética).

Para avaliar seu impacto, definimos um experimento A/B no qual:

- o **grupo controle** utiliza a estratégia atual de seleção de telefones (aleatório ou ordem alfabética);
- o **grupo tratamento** utiliza o ranking gerado pelo `PhoneScorer`.

O objetivo é verificar se a nova abordagem produz ganhos reais no motor de disparos de WhatsApp, com base em métricas de engajamento bem definidas ao longo de um período controlado.

6.2 Métricas

6.2.1 Métrica Primária

Proporção de CPFs com alta taxa de leitura:

A taxa de leitura por CPF é definida como:

$$\text{ReadRate}_{\text{CPF}} = \frac{\text{Total de mensagens lidas}}{\text{Total de mensagens enviadas}}$$

Definimos a variável indicadora:

$$\text{HighRead}_{\text{CPF}} = \begin{cases} 1, & \text{se ReadRate}_{\text{CPF}} \geq 0.75 \\ 0, & \text{caso contrário} \end{cases}$$

A métrica primária é:

$$p_{\text{read}} = \frac{\sum \text{HighRead}_{\text{CPF}}}{n}$$

onde n é o número total de CPFs considerados no experimento.

6.2.2 Métrica Secundária

Proporção de CPFs com alta taxa de entrega:

A taxa de entrega por CPF é definida como:

$$\text{DeliveryRate}_{\text{CPF}} = \frac{\text{Mensagens com status delivered ou read}}{\text{Total de mensagens enviadas}}$$

Definimos a variável indicadora:

$$\text{HighDelivery}_{\text{CPF}} = \begin{cases} 1, & \text{se DeliveryRate}_{\text{CPF}} \geq 0.9 \\ 0, & \text{caso contrário} \end{cases}$$

A métrica secundária é:

$$p_{\text{delivery}} = \frac{\sum \text{HighDelivery}_{\text{CPF}}}{n}$$

6.3 Hipóteses

6.3.1 Hipótese Nula (H_0)

$$H_0 : p_{\text{read, tratamento}} \leq p_{\text{read, controle}}$$

A hipótese nula afirma que o grupo tratamento (`PhoneScorer`) não aumenta a proporção de CPFs com alta taxa de leitura em relação ao grupo controle.

6.3.2 Hipótese Alternativa (H_1)

$$H_1 : p_{\text{read, tratamento}} > p_{\text{read, controle}}$$

A hipótese alternativa afirma que o grupo tratamento (`PhoneScorer`) aumenta a proporção de CPFs com alta taxa de leitura em relação ao grupo controle.

6.4 Teste Estatístico

A comparação entre os grupos é realizada por meio de um **teste de duas proporções (z-test)**, adequado para avaliar diferenças entre proporções em amostras independentes.

O teste é conduzido de forma unilateral à direita, com nível de significância $\alpha = 0.05$, avaliando se:

$$p_{\text{read, tratamento}} > p_{\text{read, controle}}$$

Rejeita-se H_0 se o p-value < 0.05.

A decisão final considera evidência de melhoria na métrica primária sem degradação relevante na métrica secundária.

6.5 Cálculo de Tamanho de Amostra

O tamanho de amostra necessário para o experimento foi estimado com base na métrica primária (proporção de CPFs com alta taxa de leitura).

Para o cálculo, foi utilizada a calculadora de Evan Miller:
https://www.evanmiller.org/ab-testing/sample-size.html

Os parâmetros foram definidos a partir da análise exploratória realizada no notebook 07_proporcao_cpfs_taxas.ipynb.

- **Baseline (taxa atual)**: 70%, correspondente à proporção observada de CPFs com taxa de leitura $\geq$ 75% (69.94% em 268,436 CPFs analisados).
- **Minimum Detectable Effect (MDE)**: 5 pontos percentuais, representando um aumento de 70% para 75%.
- **Nível de significância**: $\alpha = 0.05$
- **Poder estatístico**: $1 - \beta = 0.80$

Com esses parâmetros, o tamanho de amostra estimado foi de aproximadamente:

$$n \approx 1{,}335 \text{ CPFs por grupo}$$

6.6 Duração do Experimento

A duração do experimento foi definida considerando o tamanho de amostra necessário e a variação temporal no comportamento dos usuários. Recomenda-se uma duração mínima de **7 dias consecutivos**, suficiente para capturar um ciclo semanal completo (dias úteis e finais de semana).

Com base no tamanho de amostra estimado de aproximadamente 2,670 CPFs no total, é necessário observar em média cerca de:

$$\approx 382 \text{ CPFs por dia}$$

para atingir o volume necessário ao longo de 7 dias.

Adicionalmente, para cada mensagem enviada, considera-se uma janela de **24 horas** para observação de leitura. Dessa forma, as métricas de leitura e entrega são sempre calculadas considerando esse mesmo horizonte temporal, assegurando consistência entre os grupos.

6.7 Design do Experimento

Aspecto	**Grupo Controle**	**Grupo Tratamento**
Estratégia de Seleção	Aleatória ou alfabética (atual)	PhoneScorer
Critério de Alocação	Aleatório por CPF (50/50)	
Tamanho	1.335 CPFs por grupo	
Período	7 dias consecutivos	

Tabela 8: Estrutura do Teste A/B: alocação aleatória de CPFs a controle e tratamento.

Definições do Experimento

- **Unidade de Randomização:** CPF (não telefone). Cada CPF é alocado uma única vez a um dos grupos no início do experimento.
- **Persistência da Alocação:** A alocação é fixa ao longo de todo o experimento (*sticky assignment*), garantindo que um mesmo CPF não transite entre controle e tratamento.
- **Unidade de Análise:** As métricas são agregadas no nível de CPF.
- **Regra de Exposição:** Para cada CPF, o grupo tratamento (PhoneScorer) seleciona o **telefone com maior score** (top-1) para envio da mensagem. O grupo controle segue a estratégia atual (aleatória ou alfabética).
- **Janela de Observação:** Para cada mensagem enviada, o status de entrega e leitura é avaliado após uma janela fixa de 24 horas.
- **Critérios de Inclusão:** A análise considera apenas mensagens com janela de observação completa de 24 horas. CPFs sem envios no período não são incluídos no cálculo das métricas.
- **Balanceamento:** A alocação é realizada de forma balanceada entre os grupos (50/50), resultando em aproximadamente 1.335 CPFs por grupo.
- **Independência:** Cada CPF é tratado como uma observação independente no experimento.